

目录

科研入门培训.....	2
一、培养目标.....	2
1. 深度学习/机器学习的基本原理	2
2. 深度学习代码的基本功.....	2
3. 科研基础.....	2
4. 计算机视觉.....	2
5. 基本的 PPT 制作技能	3
二、入门培训内容.....	4
1. 深度学习的基本原理和代码功底（一周左右）：	4
2. 科研基础（1 天左右）	5
3. 文献阅读（5-20 天左右）	5
三、入门考核内容.....	6
1. 基础知识.....	6
2. 文献阅读.....	7
3. 代码复现.....	8
4. PPT 汇报.....	9
四、其他学习资源.....	11
1. 对抗攻击.....	11
参考文献.....	12

科研入门培训

一、培养目标

本科生科研主要的培养目标包括：

- 了解人工智能基础知识，读懂前沿算法代码，学会运用前沿技术解决问题
- 掌握科研基本流程，锻炼严谨的科研思维，熟练运用各类科研工具和文献技巧
- 探索创新性 Idea 并实现，在本领域顶级会议/期刊上发表论文，参与国内外学术会议交流学习
- 转换科研项目成果（大创、挑战杯等），斩获各种竞赛奖项

二、入门培训内容

入门培训时长一个月，希望能在培训任务的指引下，带领你掌握以下内容：

1. 深度学习/机器学习的基本原理

数据集、模型、训练的概念与原理等；掌握计算机视觉方向的常见任务。

2. 深度学习代码基本功

（1）对 Python、PyTorch 有基本的了解，清楚 Anaconda 的作用；（2）能在给出 GitHub 仓库的情况下，根据论文内容复现/跑通代码；（3）能对已有代码进行改进；（4）能使用 Linux 系统服务器进行深度学习任务。

3. 科研基础

了解什么是 CCF 推荐会议/期刊、arXiv，如何检索文献、做文献笔记和论文调研报告，如何管理文献(Zotero)。

4. 计算机视觉

了解计算机视觉的基本原理，了解诸如分类模型中的 AlexNet、ResNet 等经典卷积神经网络模型，了解以 Transformer 技术为基础的视觉模型 ViT 及其后续衍生，能够简单、基本的视觉任务训练及测试 Pipeline（手写数字识别、检测等...）。

5. 基本的 PPT 制作技能

规范完成组会汇报 PPT。

三、培训资料与时间安排

目的：一个月左右，主要考核是否对科研是否有兴趣，愿意投入。

1. 深度学习的基本原理和代码功底（一周左右）：

（1）机器学习课程

- 参考[李宏毅的机器学习课程](#)，学习机器学习、深度学习的基本原理（快速扫完）：只需学习 2/18, 2/25, 3/04, 3/25, 4/22, 4/29, 5/06 这几日的课程，其余课程内容目前不用学习。在听课程内容时，**优先听 Class Material**，其余的 Preparation-zh 和 Extra Material 作为补充；4/22, 4/29, 5/06 的课程只听 Preparation-zh；
- 3/18（注意力机制），**优先听 Class Material**，其余的 Preparation-zh 和 Extra Material 作为补充；
- 建议在 **1-4 天之内** 完成上述课程。
- 完成[李宏毅的机器学习课程](#)中课后作业：HW3，在 Slide 中查看作业要求，在 Submission 中可以找到作业需要的数据集以及完整的代码，至少要跑通上面的代码，并给出实验结果。

（2）Python 语言

如果对 Python 语言没有太多了解，可以先学习 [Python 基础教程](#)，也可以学习 <https://cs231n.github.io/python-numpy-tutorial/> 和 [Jupyter Notebook 教程](#)。对 Linux 不熟练的，学习 [Linux 基础教程](#)。

（3）Git

对 Git 不熟悉的，学习[一小时 Git 教程](#)。

（4）PyTorch 框架

PyTorch 的学习，建议在掌握理论知识，听完了李宏毅老师的课程的基础上，学习 [PyTorch 官方文档](#) 给出的教程和几个示例（选择性）。同时，**强烈推荐**学习 [小土堆的教程](#)（如果想快点上手，重点推荐这个教程）。

（5）其他参考

也可以参考这个链接：[GitHub - Ovoice/learning-Journey-AI: learning-Journey-AI 是一个 2025 年最新整理推出 AI 学习资料归纳，包含了基础理论知识，书籍，文章和论文以方便学习，还提供了各种实战项目和工具以方便练习。 · GitHub](#)

同样包括：python 编程、机器学习、深度学习等基础知识，并且有实战项目案例，如 **PyTorch**，图像分类、卷积神经网络、迁移学习等：
<https://github.com/Ovoice/learning-Journey-AI/tree/main/Project/Phase2>

2. 科研基础（1天左右）

通过网络搜索，了解什么是 arXiv、什么是 Overleaf；并初步了解如何使用 Zotero 等文献管理软件，如何做文献笔记和论文调研报告，熟练使用 Google Scholar、PapersWith Code 检索高质量论文；学习使用 Powerpoint，或者可选 LaTeX 的 Beamer 包完成汇报 PPT 的制作；了解 BibTeX，知道参考文献的几种写法和格式（如 GB/T 7714-2025 国标）。对 LaTeX 不熟悉的同学请学习 [LaTeX 基础教程](#)。

3. 文献阅读（5-20 天左右）

这部分主要是为你打下 AI 的研究基础。你可以选择**对抗攻击、深度伪造（伪造生成、伪造检测、主动防御）作为主要方向**，需要阅读一些相关领域的经典论文，复现其中的一些未来常用的方法论文，并完成一份文献阅读报告，为自己未来在研究生期间的工作打下坚实的基础。

四、入门考核内容

目的：理解科研的组成部分，明白如何进入科研的模式。**字数、内容都不作为好坏的标准，我们希望你能够在这个过程中得到提升，不仅知识水平，还有自学能力。**

内容包括但不限于：

1. 基础知识

(1) 对抗攻击

了解对抗样本攻击的基本概念与研究背景[1,2]，理解数字对抗攻击和物理对抗攻击、白盒攻击和黑盒攻击、目标攻击和无目标攻击。

熟悉经典的数字对抗攻击算法：FGSM[3]、PGD[4]、JSMA[5]、DeepFool[6]与 C&W[7]等，理解它们的攻击原理、扰动生成机制和优化目标。

了解物理对抗攻击的研究现状[8]，理解光学物理对抗攻击机制与方法：激光攻击（AdvLB）[9]、阴影攻击（AdvShadow）[10]，了解光照、角度、距离、打印失真等环境因素对物理对抗攻击效果的影响。

学习本课题组的前期工作：基于照明光调制的物理对抗攻击[11]、面向人脸的光学物理对抗攻击[12]、针对自动驾驶中交通标志识别系统的 LED 照明调制对抗攻击[13]、面向车道线的跨任务物理对抗攻击[14]、基于注意力引导的强迁移性物理对抗攻击[15]。

思考以下问题：数字对抗攻击与物理对抗攻击各自的优劣？与数字对抗攻击相比，物理对抗攻击在扰动在设计上需要考虑有哪些因素（如扰动鲁棒性）？攻击的迁移性（Transferability）是指什么？

(2) 深度伪造

- **伪造生成：**了解人脸合成与人脸篡改的基础概念与研究背景[16]，掌握伪造生成的基本流程。

学习三类主流技术路线：基于自编码器（AutoEncoder）的伪造生成（如 ALAE 人脸属性编辑[17]）、基于生成对抗网络（GAN）的伪造生成（如 StarGAN 人脸属性编辑[18]、StyleGAN[19]、S2Swap 人脸替换[20]）、基于扩散模型的伪造生成（如 DDPM[21]、Stable Diffusion[22]）。

理解各类方法的基础概念与技术流程。

思考以下问题：自编码器、GAN 和扩散模型三类生成框架在伪造生成中的优化目标和学习流程有何不同？

- **伪造检测：**了解面向图像和视频的伪造检测基础概念与研究背景[23,24]，掌握分类检测与伪造区域定位的基本流程，重点学习三类检测方法：

空域检测方法（直接利用 RGB 空间特征，如 Xception、EfficientNet 等骨干网络，基于人脸身份特征不一致性检测（IID）[25]）、频域检测方法（利用 DCT、傅里叶变换等捕获频域伪影，如 FreqNet [26]、HFI-Net [27]）、时域视频检测方法（关键帧检测[28,29]，利用帧间时序不一致性与动态纹理，如 DFGaze[30]）。

思考以下问题：为什么基于深度学习的检测器在已知伪造方法上表现优异，但面对未知生成器或跨数据集测试时泛化性能会显著下降？空域、频域、时域三类检测线索分别捕获了伪造过程中的哪些不同痕迹？检测任务中常用的损失函数（如交叉熵）和评估指标（如 ACC、AUC）有哪些，各自起到什么作用？

- **主动防御：**了解主动防御的基础概念与研究背景[31,32]，了解主动防御与伪造检测的区别。

了解基于扭曲攻击的主动防御技术（在使伪造模型的输出图像产生显著的视觉失真或扭曲[33,34]）、基于无效攻击的主动防御技术[35,36]。

思考以下问题：主动防御与被动检测的本质区别是什么？如何在不可感知性、对生成模型的干扰强度和对正常视觉质量的保持之间取得平衡？

（3）考核方式

面试提问。

2. 文献阅读

文献阅读报告目的是**训练论文理解、方法提炼与科研思考能力**，需按固定模板结构撰写，重点把握**论文创新价值**。

（1）内容要求

论文阅读报告的内容应包括：论文引用、论文标题、作者单位、论文背景和问题、论文采用的方法和创新点、论文取得的效果及实验分析、总结和自己的思考等，撰写阅读报告时可以参考论文原文、博客、专栏的解读，但注意重点关注背景的背景、问题、方法部分，实验部分适当取舍阅读，思考部分可以写写自己的想法、对文章的理解。

（2）规范说明

- 提炼论文摘要，清晰把握全文定位；
- 明确文章针对的问题：背景、难点、研究意义；
- 梳理采用的方法：对比前人不足，提炼本文创新点；

- 总结实验与效果：说明实验方案、关键指标、量化提升；
- 写出自己的感受：对自身课题的借鉴意义或可改进之处。

具体文献阅读报告的格式请找导师或师兄师姐要。

(3) 考核方式

你需要任意挑选一个方向，挑选其中的 **2-3 篇** 论文阅读、完成文献阅读报告，并做一个 10min 左右的 PPT 对这两篇论文进行展示。阅读和展示考核文献时，你尤其需要思考：本文的创新点在哪里？未来是否还有能继续研究的空间？你的思考是什么？

(4) 经验建议

在你刚开始看论文的时候，可能会看到一些复杂公式不好理解，容易望而生畏，这里有一些经验建议：

- 跳过公式，理解算法核心，做概念抽象的理解；
- 看论文抓住核心（问题、动机、方法），粗读的论文看看 Abstract 和 Introduction，方法不需要太深入纠结，需要作为 coding base 或者重要的 paper 再深入理解；
- 结合知乎/CSDN 或者优秀帖子看（或者用 GPT/Gemini 辅助阅读），先用中文和别人嚼碎的，会好接受一点；
- 需要深入了解的论文：结合代码跑着（断点调试），理解抓住数据 input 和 output，数据在整个 model 是如何流动的（forward）（关注 matrix shape）。

3. 代码复现

(1) 复现要求

你需要在选择的的方向的中挑选任意 2 个文献（参考【1.基础知识】中给出的文献），根据他们给出的 GitHub 仓库跑通代码，提供跑通训练 pipeline 到 test 的完整流程，并对比其是否和原文中的结果吻合。建议选择最新的文献完成代码复现。

(2) 规范说明

- 写好完整的实验时间、目的，明确实验目标；
- 记录环境：CPU、GPU、Python、框架、依赖包版本。
- 记录完整的实验过程、关键步骤和执行命令。
- 记录结果、输出、报错、修改操作。

- 总结实验的结果：解决的问题、存在的问题、原因分析。

(3) 提醒：

- 最好边做实验边记录结果，不事后补写，以免遗忘或复现出现偏差。
- 遇到错误务必记录日志与解决方案。
- 复现实验严格对齐原文配置，保证可比。
- 内容真实完整，不省略关键细节。

具体实验记录报告的格式请找导师或师兄师姐要。

(3) 考核方式

代码复现报告，附在文献阅读报告后，展示实验结果，并简单说明复现过程中遇到的问题和解决方案。

4. PPT 汇报

PPT 汇报的本质是**清晰展示工作进展、暴露问题、对齐后续计划**，不是形式化任务，希望你能够在这个过程中训练自己**问题提炼、反思总结的能力。**

(1) 内容要求

在完成上述 1-3 小节的内容后，你需要挑选 2-3 篇论文进行汇报，遵循**逻辑清晰、结构完整、重点突出**的原则，按照固定框架组织内容，保证老师和同学能快速理解工作内容。

(2) 规范说明

● 内容撰写规范：

- 内容必须简洁、要点化，避免大段文字堆砌，每页只讲 **1-2** 个核心信息；
- 工作进展需**具体可量化**，不写空话、套话，明确“做了什么、做到什么程度、得到什么结果”；
- 问题与结论分开写：问题突出**困难、不足、待改进之处**，结论突出**收获与发现**；
- 下一步安排要**可执行、有时间预期、有明确目标**，不写模糊计划。

● 格式与排版规范：

- 统一使用模板给定版式，保持字体、字号、颜色、项目符号一致；
- 标题明确、层级清晰，使用**序号 + 要点**形式呈现；
- 图表、数据需标注来源并解释说明，保证可读性与可信度；

- 最后一页必须包含参考文献，格式规范统一。

具体的 PPT 格式请找导师或师兄师姐要。

(3) 考核方式

面试提问。

四、其他学习资源

1. LLM 相关

做 LLM 相关可以速览一遍：[大模型入门教程](#)，coding 可以完成：[从零开始训练大模型](#)

2. 对抗攻击

(1) 物理对抗攻击与对抗防御方法整理

[GitHub - jiakaiwangCN/awesome-physical-adversarial-examples · GitHub](#)

(2) 开源代码库与工具包

- **Torchattacks:** [GitHub - Harry24k/adversarial-attacks-pytorch: PyTorch implementation of adversarial attacks \[torchattacks\] · GitHub](#)
- **TransferAttack:** [GitHub - Trustworthy-AI-Group/TransferAttack: TransferAttack 是一个 pytorch 框架，旨在提升图像分类的对抗性转移能力。 · GitHub](#)

参考文献

- [1] Akhtar N, Mian A, Kardan N, et al. Advances in adversarial attacks and defenses in computer vision: A survey[J]. IEEE Access, 2021, 9: 155161-155196.
- [2] Wang D H, Yao W, Jiang T S, et al. A survey on physical adversarial attack in computer vision[EB/OL]. arXiv:2209.14262, 2022.
- [3] Fang J B, Jiang Y, Jiang C J, et al. State-of-the-art optical-based physical adversarial attacks for deep learning computer vision systems[J]. Expert Systems with Applications, 2024, 250: 123761.
- [4] Goodfellow I J, Shlens J, Szegedy C. Explaining and harnessing adversarial examples[EB/OL]. arXiv:1412.6572, 2014.
- [5] Madry A, Makelov A, Schmidt L, et al. Towards deep learning models resistant to adversarial attacks[EB/OL]. arXiv:1706.06083, 2017.
- [6] Papernot N, McDaniel P, Jha S, et al. The limitations of deep learning in adversarial settings[C]//2016 IEEE European Symposium on Security and Privacy. IEEE, 2016: 372-387.
- [7] Moosavi-Dezfooli S M, Fawzi A, Frossard P. Deepfool: A simple and accurate method to fool deep neural networks[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016: 2574-2582.
- [8] Carlini N, Wagner D. Towards evaluating the robustness of neural networks[C]//2017 IEEE Symposium on Security and Privacy. IEEE, 2017: 39-57.
- [9] Chen Z J, Lin P X, Jiang Z L, et al. An illumination modulation-based adversarial attack against automated face recognition system[C]//16th International Conference on Information Security and Cryptology. 2020.
- [10] Fang J B, Jiang C J, Jiang Y, et al. Imperceptible physical attack against face recognition systems via LED illumination modulation[J]. IEEE Transactions on Big Data, 2024.
- [11] Fang J B, Shen Y X, Sun Y J, et al. LIMA: Towards building a non-invasive and stealthy real-world adversarial attack model for traffic sign recognition systems[J]. Neural Networks, 2026, 197: 108497.
- [12] Jiang Y, Wang Y D, Luo Y Q, et al. AdvLIM-LD: Toward cross-task physical adversarial attack via LED illumination modulation for lane detection systems[J]. IEEE Internet of Things Journal, 2025, 12(22): 47000-47010.
- [13] Jiang Y, Luo Y Q, Fang J B, et al. A real world attack model combining LED modulation and attention-superpixel guidance[J]. Expert Systems with Applications, 2025, 293: 128589.

- [14] Duan R J, Mao X F, Qin A K, et al. Adversarial laser beam: Effective physical-world attack to DNNs in a blink[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021.
- [15] Zhong Y Q, Liu X, Zhai D, et al. Shadows can be dangerous: Stealthy and effective physical-world adversarial attack by natural phenomenon[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022.
- [16] Edwards P, Nebel J C, Greenhill D, et al. A review of deepfake techniques: Architecture, detection, and datasets[J]. IEEE Access, 2024, 12: 154718-154742.
- [17] Pidhorskyi S, Adjeroh D A, Doretto G. Adversarial latent autoencoders[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 14104-14113.
- [18] Choi Y, Choi M, Kim M, et al. StarGAN: Unified generative adversarial networks for multi-domain image-to-image translation[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2018: 8789-8797.
- [19] Karras T, Laine S, Aila T. A style-based generator architecture for generative adversarial networks[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2019: 4401-4410.
- [20] Chen R, Chen X, Ni B, et al. SimSwap: An efficient framework for high fidelity face swapping[C]//Proceedings of the 28th ACM International Conference on Multimedia. 2020: 2003-2011.
- [21] Dhariwal P, Nichol A. Diffusion models beat GANs on image synthesis[J]. Advances in Neural Information Processing Systems, 2021, 34: 8780-8794.
- [22] Rombach R, Blattmann A, Lorenz D, et al. High-resolution image synthesis with latent diffusion models[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 10684-10695.
- [23] Wang T Y, Liao X, Chow K P, et al. Deepfake detection: A comprehensive survey from the reliability perspective[J]. ACM Computing Surveys, 2024, 57(3): 1-35.
- [24] Sharma V K, Garg R, Caudron Q. A systematic literature review on deepfake detection techniques[J]. Multimedia Tools and Applications, 2025, 84(20): 22187-22229.
- [25] Huang B J, Wang Z Y, Yang J F, et al. Implicit identity driven deepfake face swapping detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 4490-4499.

- [26] Tan C, Zhao Y, Wei S, et al. Frequency-aware deepfake detection: Improving generalizability through frequency space domain learning[C]//Proceedings of the AAAI Conference on Artificial Intelligence, 2024, 38(5): 5052-5060.
- [27] Miao C, Tan Z, Chu Q, et al. Hierarchical frequency-assisted interactive networks for face manipulation detection[J]. IEEE Transactions on Information Forensics and Security, 2022, 17: 3008-3021.
- [28] Wang T, Cheng H, Chow K P, et al. Deep convolutional pooling transformer for deepfake detection[J]. ACM Transactions on Multimedia Computing, Communications and Applications, 2023, 19(6): 1-20.
- [29] Wang T, Chow K P. Noise based deepfake detection via multi-head relative-interaction[C]//Proceedings of the AAAI Conference on Artificial Intelligence, 2023, 37(12): 14548-14556.
- [30] Guo X, Liu X, Ren Z, et al. Hierarchical fine-grained image forgery detection and localization[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 3155-3165.
- [31] Ruiz N, Bargal S A, Sclaroff S. Disrupting deepfakes: Adversarial attacks against conditional image translation networks and facial manipulation systems[C]//Computer Vision—ECCV 2020 Workshops. Springer, 2020: 236-251.
- [32] Yeh C Y, Chen H W, Tsai S L, et al. Disrupting image-translation-based deepfake algorithms with adversarial attacks[C]//Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision Workshops. 2020: 53-62.
- [33] Huang H, Wang Y, Chen Z, et al. CMUA-watermark: A cross-model universal adversarial watermark for combating deepfakes[C]//Proceedings of the AAAI Conference on Artificial Intelligence, 2022, 36(1): 989-997.
- [34] Dong J, Wang Y, Lai J, et al. Restricted black-box adversarial attack against deepfake face swapping[J]. IEEE Transactions on Information Forensics and Security, 2023, 18: 2596-2608.
- [35] Zeng S, Wang W, Huang F, et al. LOFT: Latent space optimization and generator fine-tuning for defending against deepfakes[C]//ICASSP 2024 IEEE International Conference on Acoustics, Speech and Signal Processing. IEEE, 2024: 4750-4754.
- [36] Jiang T, Yu H, Meng W, et al. Towards retentive proactive defense against DeepFakes[C]//International Conference on Testbeds and Research Infrastructures. Springer Nature Switzerland, 2023: 139-153.